一文搞懂什么是ablation study (消融实验)

by 知乎 https://zhuanlan.zhihu.com/p/644502891

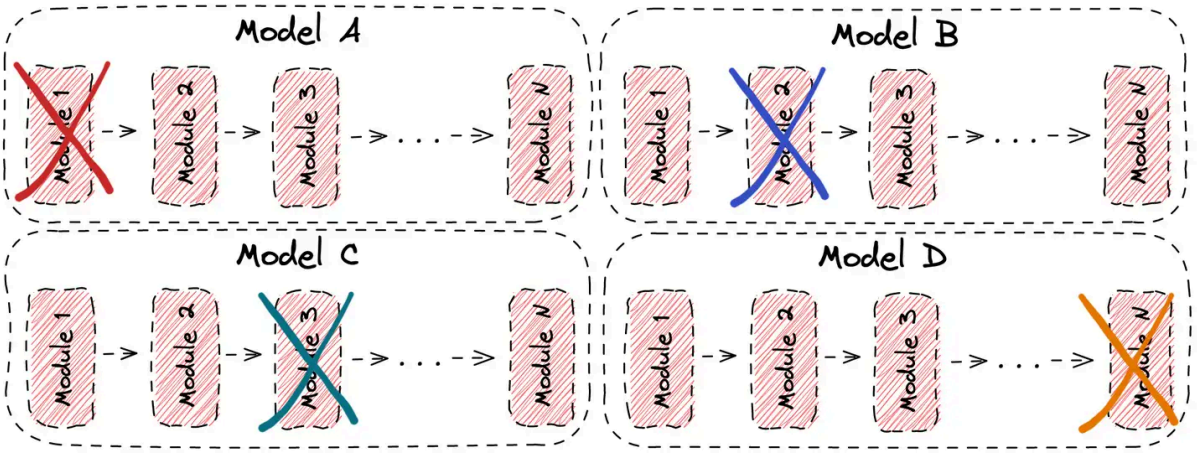

消融实验是在科研论文中经常见到的一个名字，在解释模型工作原理的因果性中起到了很大作用，是科研环节中必不可少的一个环节。

Francois Chollet, Keras深度学习框架的作者之一认为：

> Ablation studies are crucial for deep learning research -- can't stress this enough. Understanding causality in your system is the most straightforward way to generate reliable knowledge (the goal of any research). And ablation is a very low-effort way to look into causality.
>
> If you take any complicated deep learning experimental setup, chances are you can remove a few modules (or replace some trained features with random ones) with no loss of performance. Get rid of the noise in the research process: do ablation studies.
>
> Can't fully understand your system? Many moving parts? Want to make sure the reason it's working is really related to your hypothesis? Try removing stuff. Spend at least ~10% of your experimentation time on an honest effort to disprove your thesis.

本文将探讨如何的设计消融实验，并且附有栗子~

狭义上的消融实验

消融 的原意是通过手术切除身体组织。消融研究“Ablation study”一词起源于 20 世纪 60 年代和 70 年代的实验神经心理学领域，通过切除部分动物大脑来研究这对动物行为的影响。

在机器学习领域，尤其是复杂的深度神经网络中，"消融研究 "被用来描述切除网络某些部分的过程，以便更好地了解网络的行为。

例如，Girshick 及其同事（2014 年）提出了一个由三个 "模块 "组成的物体检测系统 RCNN：第一个模块使用选择性搜索算法（Uijlings 及其同事，2012 年）提出在图像中搜索物体的区域，然后输入一个大型卷积神经网络（有 5 个卷积层和 2 个全连接层）进行特征提取，再输入一组支持向量机进行分类。为了更好地了解该系统，作者进行了一项消融研究，移除系统的不同部分--例如，移除卷积神经网络的一个或两个全连接层，性能损失却出奇地小，这让作者得出以下结论，

> Much of the CNN’s representational power comes from its convolutional layers, rather than from the much larger densely connected layers.

可以看出，消融实验的目的在于**移除**系统中的特定的部分，来控制变量式的研究这个部分对于系统整体的影响。如果去除这一部分后系统的性能没有太大损失，那么说明这一部分对于整个系统而言并不具有太大的重要性；如果去除之后系统性能明显的下降，则说明这一部分的设计是必不可少的。当然，如果出现了第三种情况，也就是去除之后模型的性能不降反升，那么建议找一下bug或者修改设计。

既然消融实验的目的是展示各个模块/部分对于系统的作用，那么实验的设计者应当对系统的各个模块的构成以及总体的架构有详细的了解。比如说原始的模型M是由一个模块A组成，而新的设计在M的基础上增加了B和C模块，使得现在的模型成为了A+B+C，那么就要分别单独研究模块B与C对于整个系统的影响，此时实验应该按照下面的表格设计，

metric 1	...	metric N
A (baseline)		
A+B		
A+C		
A+B+C (final)		

在上图中，metric 1 - N 表示N个用来评价系统性能的指标，比如图像分类任务中常用的top1 和 top5 error rate。原始模型M（只含有A模块）会被首先测试，得到的结果会成为baseline用来对比。接下来，分别测试模型A+B与A+C来分别测试B模块与C模块的**单独**作用。最后，就要把所有的模块都放在一起，也就是模型A+B+C，来测试最终模型的性能。

当模块C是基于模块B时，也就是不存在A+C模型的组合方式时，只需要将上表中对应A+C的行删去即可。

因此消融实验可以帮助设计出更简单且工作的模型。因此，如果可以用两种模型获得相同的性能，则优先选择更简单的模型。

广义上的消融实验

在上节中，我们了解到到消融实验就是去除系统中的某个特定的模块来探究这个模块对于系统的作用，这也和消融实验的名字是相对应的。然鹅，在现在的机器学习的语境下，消融实验并不单单局限于去除某一个部分，而可以包括更多的内容，也就形成了广义上的消融实验。

我们知道，消融实验的本质上就是控制变量研究单个变量的作用。针对那些**无法去除的变量**，比如超参数的选择，这时候总不能说让我们把超参数直接去掉来研究它的影响，因此在这种情况下应该应该选择控制系统的其他方面不变，来测试一组超参数来研究这个参数对于系统的影响。因此，超参数调参常用的grid search和random search本质上也是消融实验，它们探究了在只改变一个参数的情况下系统性能的变化从而展示参数对于系统的影响。

另外，如果系统设计中所涉及的变量较多时，应当合理选择哪些变量是更值得用ablation study方法来论述其作用/重要性。对于那些不太重要的参数，可以调小搜索范围或者使用常用的数值。

荐参考Faster RCNN论文来学习针对变量的消融实验的设计，非常好的学习素材。

总结

消融实验是希望探究某一个单一变量对于系统的影响。**针对可以去除的部分/模块/选项，可以采用去除的方式来设计实验；而针对不可以去除的变量/超参数等，可以采用grid search等方法来展示参数对于系统的影响。**好的论文离不开详实的消融实验来让读者跟好的了解自己的贡献，以及加深对于新提出的模块的作用的理解。总而言之，设计消融实验时，应该注意**单尺度叙事原则**，即一次只控制一个变量，进而研究该变量对于系统的影响。